

Regression & correlation methods

헬스케어데이터분석개론 10강

지상아


삼성서울병원 의학통계센터


sszzgg91@naver.com

- Correlation methods
- Regression model
 - Simple linear regression
 - Multiple linear regression

Correlation methods

[Remind] 변수/자료 유형에 따른 검정법 선정 - 차이 검정





[Remind] 범주형 자료 vs 범주형 자료

부작용 발생 백신종류	발생	미발생	전체
기존 백신	50 (10%)	450 (90%)	500
새 백신	60 (20%)	240 (80%)	300
전체	110 (13.75%)	690 (86.25%)	800

가설

H_0 : 기존 백신과 새 백신의 부작용 발생률은 같다
 H_1 : 기존 백신과 새 백신의 부작용 발생률은 다르다



가설

H_0 : 백신의 종류와 부작용 발생 여부는 연관성이 없다
 H_1 : 백신의 종류와 부작용 발생 여부는 연관성이 있다



가설

H_0 : 백신의 종류와 부작용 발생 여부는 독립적인 관계이다
 H_1 : 백신의 종류와 부작용 발생 여부는 독립적인 관계가 아니다

검정법

Parametric

Chi-square test


Nonparametric

Fisher's exact test

- 산점도 (scatter plot)
 - 두 변수 사이의 선형관계가 있는지를 확인할 수 있음
 - 이상치, 클러스터(그룹)의 존재를 식별할 수 있음


Ex. 키와 체중 간의 관계

: 키가 클수록 체중이 늘어난다
(선형관계 있음)




Ex. 나이와 키 간의 관계


: 나이가 들수록 키가 늘어난다고 할 수는 없다
(선형관계 없음)



- Correlation analysis (상관 분석)
 - 두 변수 간의 연관성 (association)의 정도(strength)와 방향(direction)을 측정하는 방법
- 상관계수 (correlation coefficient, r, ρ) ($-1 \leq r \leq 1$)
 - 두 변수의 상관관계 (correlation)를 나타내는 값
 - 크기와 방향으로 설명






Scatter Plots & Correlation Examples



- Correlation analysis (상관 분석)
 - 두 변수 간의 연관성 (association)의 정도(strength)와 방향(direction)을 측정하는 방법
- Pearson's (product-moment) correlation coefficient (피어슨 상관계수)
 - 정규성 가정 만족시 사용
 - 두 연속형 변수의 선형 관계 (linear relationship)을 측정
 - 이상치(outlier)에 민감
Ex. Height가 1단위 증가하면 Weight가 일정하게 변하는지
- Spearman's rank correlation coefficient (스피어만 상관계수)
 - 정규성 가정 위반시 사용
 - 두 연속형 변수의 순서/순위 관계 (monotone relationship)을 측정
 - 이상치(outlier)에 덜 민감
Ex. 시험 등수가 증가하면 소득이 증가하는지

Pearson's Correlation vs Spearman's Correlation



- Spearman correlation detects monotone relationship even though it's non-linear

- Spearman correlation is less sensitive to strong outliers

Birthweight 자료에서 산모의 나이(age)와 마지막 생리 때의 산모 체중(lwt)간에 상관관계가 있는지를 검정하고, 두 변수 간 상관계수를 추정하라.

가설

H_0 : 산모의 나이와 마지막 생리 때의 산모 체중이 상관관계가 없다. ($r = 0$)
 H_1 : 산모의 나이와 마지막 생리 때의 산모 체중이 **상관관계가 있다**. ($r \neq 0$)

유의수준

0.05

정규성 가정 위반 검정법

Shapiro-Wilk test

데이터 가져오기

```
data <- read.csv('C:/Users/sangahchi/Downloads/10/birthweight.csv', header=T, stringsAsFactors = F)
```

정규성 가정 위반 검정 (Shapiro-Wilk test)

```
with(data, shapiro.test(age))
```

```
with(data, shapiro.test(lwt))
```

Scatter plot with linear line


```
ggplot(aes(x=age, y=lwt), data=data) +  
  geom_point() +  
  geom_smooth(method=lm) +  
  theme_bw()
```

shapiro-wilk normality test

data: age
W = 0.95977, p-value = 0.00003189

shapiro-wilk normality test

data: lwt
W = 0.89331, p-value = 0.0000000002242



Birthweight 자료에서 산모의 나이(age)와 마지막 생리 때의 산모 체중(lwt)간에 상관관계가 있는지를 검정하고, 두 변수 간 상관계수를 추정하라.

가설

H_0 : 산모의 나이와 마지막 생리 때의 산모 체중이 상관관계가 없다. ($r = 0$)
 H_1 : 산모의 나이와 마지막 생리 때의 산모 체중이 **상관관계가 있다**. ($r \neq 0$)

유의수준

0.05

검정법

Spearman correlation test

```
# Spearman correlation test  
with(data, cor.test(age, lwt, method = "spearman", exact=FALSE))
```

참고. Pearson correlation test

- cor.test()
- method="pearson"

spearman's rank correlation rho

```
data: age and lwt  
S = 915827, p-value = 0.01037  
alternative hypothesis: true rho is not equal to 0  
sample estimates:  
rho  
0.1860614
```

유의성 판단 (결론)

두 변수는 유의한 상관관계가 있으며, 약 0.19의 상관계수로 약한 양적 상관관계를 가진다.

r	해석
(-1, -0.7)	강한 음적 상관관계
(-0.7, -0.3)	뚜렷한 음적 상관관계
(-0.3, -0.1)	약한 음적 상관관계
(-0.1, 0.1)	거의 무시될 수 있는 상관관계
(0.1, 0.3)	약한 양적 상관관계
(0.3, 0.7)	뚜렷한 양적 상관관계
(0.7, 1)	강한 양적 상관관계

범주형

No difference in Y according to X

Significance in Chi-square test or Fisher's exact test



No association between X and Y




Independent relationship between X and Y

연속형

No correlation between X and Y

$r_{XY} = 0$ (No significance in correlation analysis)



No association between X and Y



Independent relationship between X and Y

Regression Model

예시: Greene-Touchstone study (1963)


- **Objective**

Relationship between birthweight and estriol level in pregnant women near the end of their term

- **Data**


31 patients with three variable

- Patient identification number
- Measurement of estriol production over a 24-hour period (mg/24hr)
- Birthweight (in 100 gram units) of the baby



예시: Greene-Touchstone study (1963)

- Regression Line (회귀선)
: 출생시 체중 = $21.52 + 0.608 \times \text{호르몬 수치}$
 - 엄마의 호르몬 수치가 20인 아기들의 출생시 체중은 평균 3.368kg



- 변수 간 관계에서의 역할: $X \rightarrow Y$

독립/설명 변수 (independent/explanatory variable)

관계에서 **원인**으로 생각되는 변수 **X**

위험 인자 (risk factor)

Y의 원인을 설명하는 변수

예측 변수 (predictor)

Y의 예측에 기여하는 변수

종속/반응 변수 (dependent/response variable)

관계에서 **결과**로 생각되는 변수 **Y**

결과 변수

(outcome / endpoint)

- Goal
 - 결과변수 (Y)와 설명변수 (Xs)간의 **인과관계 (causal relationship)** 추론
 - 인과관계를 $Y = f(X)$ 로 모형화

$$Y = f(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_K X_K) + \epsilon$$

- 결과변수를 설명변수들의 선형 조합 (linear combination) = 가중합 (weighted sum)의 함수로 모형화
- Objectives
 - 모형의 추정, 유의성 확인, 설명력 평가
 - 결과변수 설명/예측에 대한 각 설명변수의 상대적 기여도 추정
 - 위험인자 분석 (risk factor analysis)
 - : outcome에 영향을 미치는 설명변수는 무엇인가?
 - 특정 설명변수 값에 대한 결과변수 값 예측
 - 예측 모형 (prediction modeling)
 - : 설명변수들로 outcome을 예측할 수 있는가?

- 선형회귀 (linear regression)
 - Ex. $Y = \beta_0 + \beta_1 X + \epsilon$
 - Ex. 공부시간(x)과 시험 점수(y) 관계
: 공부시간이 늘어나면 점수도 거의 비례해서 증가할 때
- 비선형회귀 (nonlinear regression)
 - Ex. $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \epsilon$
 - Ex. 시간(x)과 박테리아 수(y) 관계
: 시간이 지나면서 기하급수적으로 증식하는 경우
 - Ex. 온도(x)와 효소 활성도(y) 관계
: 특정 온도 범위에서는 증가하다가 다시 감소하는 종 모양 (포물선)

- 단변수 회귀 (univariable regression)
 - 1개의 예측변수
 - Ex. $Y = \beta_0 + \beta_1 X + \epsilon$
- 다변수 회귀 (multivariable regression)
 - 2개 이상의 예측변수
 - Ex. $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$


- 선형 회귀모형 (linear regression model)
 - 연속형 결과변수 (ex. 출생시 체중)
 - $Y = \beta_0 + \beta_1 X + \epsilon$
- 로지스틱 회귀모형 (logistic regression model)
 - 범주형 결과변수 (ex. 당뇨병 유병 여부)
 - $g(Y) = \beta_0 + \beta_1 X + \epsilon$ and **logit link function** for $g(\cdot)$
- 포아송 회귀모형 (logistic regression model)
 - 이산형 결과변수 (ex. 강원지역의 10년간 폐쇄성무호흡증 발생건수)
 - $g(Y) = \beta_0 + \beta_1 X + \epsilon$ and **log link function** for $g(\cdot)$
- 콕스 비례 회귀모형 (Cox proportional hazards regression model)
 - 생존형 결과변수 (ex. 전체 생존기간 (overall survival))
 - $g(Y) = \beta_0 + \beta_1 X + \epsilon$ and **log hazard function** for $g(\cdot)$

Regression Model


① Simple Linear Regression

- 선형 회귀모형 (linear regression model)
 - 연속형 결과변수 (ex. 출생시 체중)
- $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \varepsilon_i \sim iid N(0, \sigma^2)$ (*iid*, independent and identically distributed)
- 인과성 형태에 대한 가정
 - 선형성 (Linearity)
- 오차에 대한 가정
 - 독립성 (Independence): 각 자료의 오차들은 서로 영향을 주지 않음
 - 정규성 (Normality): 모든 오차들은 같은 정규분포를 따름
 - 등분산성 (Equal variance): 모든 오차들의 분산은 같음
 - 오차의 평균은 0 (zero mean)


- Linear relationship between Y and X
 - $Y = \beta_0 + \beta_1 X + \varepsilon$ (=deterministic model + random error)
 - Assume $\varepsilon \sim N(0, \sigma^2)$






- $\varepsilon \sim N(0, \sigma^2)$
- $E(Y) = \beta_0 + \beta_1 X$
 - Average value of Y for any fixed value of X
 - Ex. 출생시 체중 = $21.52 + 0.608 \times \text{호르몬 수치}$
→ 엄마의 호르몬 수치가 20인 아기들의 출생시 체중은 평균 3.368kg



- 모형 $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \varepsilon_i \sim iid N(0, \sigma^2)$
- Y절편 (intercept) β_0
 - 설명변수 값이 0일 때의 결과변수의 평균값
- 기울기 (slope) β_1
 - 회귀계수 (regression coefficient)
 - 설명변수의 기여도
 - 설명변수 값이 1 증가할 때 결과변수의 평균 변화량



- 모형 $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \varepsilon_i \sim iid N(0, \sigma^2)$
- 최적합 직선 (best fitting line)
 - 자료를 가장 잘 설명하는 직선
 - 자료와의 오차가 가장 작은 직선
- 오차 (error)가 최소가 되는 직선 (intercept & slope)을 찾자!



- 오차 = 관측값(자료) - 예측값(회귀모형)
- 오차제곱합 (SSE, sum of squares due to error)

$$SSE = \sum_{i=1}^n \hat{\varepsilon}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 + \hat{\beta}_1 x_i)^2$$

- 오차제곱합에 대한 편미분(partial derivative)의 결과를 0으로 만드는 $\hat{\beta}_0$ 와 $\hat{\beta}_1$ 을 추정함

$$\frac{\partial SSE}{\partial \beta_0} = 0$$



$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\frac{\partial SSE}{\partial \beta_1} = 0$$



$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

- Estimated regression line (=besting fitting line)

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

- Coefficient in the estimated model
- 설명변수의 효과 추정
 - 직선의 기울기의 추정값
 - 설명변수 값이 1단위 증가할 때 결과변수 값의 평균적인 변화량

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \quad SE(\hat{\beta}_1) = \sqrt{\sigma^2/S_{xx}} \approx \sqrt{MSE/S_{xx}} = \widehat{SE}(\hat{\beta}_1)$$

- 설명변수의 효과에 대한 유의성 확인
 - $H_0: \beta_1 = 0$ (설명변수의 효과가 없다)

- Test statistics
$$t = \frac{\hat{\beta}_1}{\widehat{SE}(\hat{\beta}_1)} \sim t(n-2)$$

- $p\text{-value} < \alpha \rightarrow H_0$ 기각
→ 추정된 회귀계수가 통계적으로 유의하다고 판단 (즉, 설명변수의 효과가 있다)

- 회귀모형의 유의성 확인
 - 추정된 회귀직선이 의미가 있는가?
 - 추정된 회귀직선이 설명하는 변동이 충분히 큰가?
- 분산분석표의 F-test의 p -value로 판정
 - H_0 : regression model is not significant (i.e., $\beta_1=0$)
 - Test statistics
$$F = \frac{MSR}{MSE} \sim F(1, n - 2)$$
 - $p\text{-value} < \alpha \rightarrow H_0$ 기각
 $\rightarrow$ 추정된 회귀식이 통계적으로 유의하다고 판단

- 결과변수 값의 변동(variation)을 두 부분으로 분해
- (결과변수 값의) 총 변동 = 예측변수가 설명하는 변동 + 오차에 의한 변동
- 예측변수가 설명하는 변동 → 회귀직선이 설명하는 변동
- 오차에 의한 변동 → 회귀직선으로 설명되지 않는 변동

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

- SST (total sum of squares)

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

- SSR (sum of squares for regression)

$$MSR = SSR$$

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

- SSE (sum of squares for error)

$$MSE = \frac{SSE}{n - 2}$$

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = SST - SSR$$

- 회귀모형의 설명력 평가
 - 추정된 회귀직선이 선형 인과관계를 얼마나 잘 설명하는가?
 - 결정계수 (coefficient of determination)를 사용하여 판단
 - 총변동에서 직선이 설명하는 변동의 비율

$$R^2 = \frac{SSR}{SST} = \frac{S_{xy}^2}{S_{xx}S_{yy}}$$

- $0 \leq R^2 \leq 1$
- $R^2 \approx 1 \rightarrow$ 설명력이 높음 $\rightarrow$ **good**
- $R^2 \approx 0 \rightarrow$ 설명력이 낮음 $\rightarrow$ **poor**


- 회귀분석 결과는 모형에 대한 가정이 만족될 때 신뢰할 수 있다!
- **인과성 형태에 대한 가정**
 - 선형성 (Linearity) → 산점도와 상관계수로 확인
- **오차에 대한 가정 → 잔차 (residual) 분석**
 - 독립성 (Independence): 각 자료의 오차들은 서로 영향을 주지 않음
 - 정규성 (Normality): 모든 오차들은 같은 정규분포를 따름
 - 등분산성 (Equal variance): 모든 오차들의 분산은 같음
 - 오차의 평균은 0 (zero mean)

- 잔차 = 관측값 - (회귀)적합값 → 오차의 추정값



$$\hat{\varepsilon}_i = y_i - \hat{y}_i$$

- 오차에 대한 가정 → 잔차 (residual)의 분포를 확인하여 가정을 확인하자!
 - 독립성 (Independence): 각 자료의 오차들은 서로 영향을 주지 않음
 - 정규성 (Normality): 모든 오차들은 같은 정규분포를 따름
 - 등분산성 (Equal variance): 모든 오차들의 분산은 같음
 - 오차의 평균은 0 (zero mean)



- 정규성 확인을 위한 시각화 도구
 - 관측값의 분포를 이론적 정규분포와 비교
 - 기준선: $y = x$ (즉, 관측값의 분포와 표준정규분포의 일치)
 - 기준선에서 많이 벗어나지 않아야 정규성을 만족한다고 판단



- 선형성, 오차의 등분산성, 오차 평균 0 확인을 위한 시각화 도구
 - 잔차값(residuals)과 적합값(fitted values)와 비교
 - 기준선: $y = 0$
 - 점들이 기준선을 중심으로 random하게 (즉, 패턴 없이 수평 띠 모양으로) 분포
 - 특정 패턴이 관찰된 경우 기본 가정 중 일부 또는 전부가 위배되는 것으로 판단함
 - Ex. 적합값이 커질수록 잔차 증가 → 등분산성 위배



- 선형성, 오차의 등분산성 확인을 위한 시각화 도구
 - 잔차값(residuals)과 설명변수값(predictor values)와 비교
 - 기준선: $y = 0$
 - 점들이 기준선을 중심으로 random하게 (즉, 패턴 없이 수평 띠 모양으로) 분포
 - 특정 패턴이 관찰된 경우 기본 가정 중 일부 또는 전부가 위배되는 것으로 판단함
 - Ex. 적합값이 커질수록 잔차 증가 → 등분산성 위배
 - Ex. 곡선 패턴 → 선형성 위배



Greene and Touchstone conducted a study to relate birthweight and estriol level in pregnant women.

As can be seen from the figure, there appears to be a relationship between estriol level and birthweight, although this relationship is not consistent and considerable scatter exists throughout the plot.

How can this relationship be quantified?

Sample data from the Greene-Touchstone study relating birthweight and estriol level in pregnant women near term

i	Estriol (mg/24 hr) x_i	Birthweight (g/100) y_i	i	Estriol (mg/24 hr) x_i	Birthweight (g/100) y_i
1	7	25	17	17	32
2	9	25	18	25	32
3	9	25	19	27	34
4	12	27	20	15	34
5	14	27	21	15	34
6	16	27	22	15	35
7	16	24	23	16	35
8	14	30	24	19	34
9	16	30	25	18	35
10	16	31	26	17	36
11	17	30	27	18	37
12	19	31	28	20	38
13	21	30	29	22	40
14	24	28	30	25	39
15	15	32	31	24	43
16	16	32			

- 모형의 유의성 확인
 - 분산분석표의 F-검정의 p -value로 판정
- 모형의 설명력 평가
 - R^2 를 사용하여 판단

```
# Greene-Touchstone
data <- data.frame(ID = 1:31,
  Estriol = c(7,9,9,12,14,16,16,14,16,16,17,19,21,24,15,16,17,25,27,15,15,15,16,19,18,17,18,20,22,25,24),
  Birthweight =
c(25,25,25,27,27,27,24,30,30,31,30,31,30,28,32,32,32,32,34,34,34,35,35,34,35,36,37,38,40,39,43))

# ANOVA
fit <- summary(aov(Birthweight ~ Estriol, data=data))

# R-squared (=250.6/(250.6 + 423.4))
fit[[1]]$`Sum Sq`[1]/sum(fit[[1]]$`Sum Sq`)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Estriol	1	250.6	250.6	17.16	0.000271 ***
Residuals	29	423.4	14.6		

```
[1] 0.3717722
```

결론

F-test의 p -value < 0.05 로 모형은 유의하며, 모형은 총 변동의 37.18%를 설명함.

- 오차의 정규성 확인
 - Normal Q-Q Plot
- 선형성, 오차의 등분산성, 오차 평균 0 확인
 - Residual Plot

기본 가정의 확인

```
res <- aov(Birthweight ~ Estriol, data=data)
```

Normal Q-Q Plot

```
qqnorm(residuals(res))
```

```
qqline(residuals(res))
```

Residual plot



```
plot(fitted(res), residuals(res),
```

```
  xlab = "Fitted values",
```

```
  ylab = "Residuals",
```

```
  main = "Residual Plot")
```

```
abline(h = 0, lty = 2)
```



결론

Normal Q-Q plot에서 기준선에 크게 벗어나지 않는 것으로 보아, 정규성을 만족하며 Residual plot에서 기준선을 중심으로 랜덤하게 발생하는 것으로 보아 선형성, 등분산성, 평균 오차 0의 가정을 만족함.

- 설명변수의 효과 추정
 - Coefficient estimate 사용
- 설명변수의 효과에 대한 유의성 확인
 - t -검정의 p -value로 판정

선형 모형 적합

```
model <- glm(Birthweight ~ Estriol, data=data)
```

Coefficient estimates

```
summary(model)
```

```
cbind(coef(model), confint(model))
```

```
call:
glm(formula = Birthweight ~ Estriol, data = data)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-8.1200	-2.0381	-0.0381	3.3537	6.8800

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	21.5234	2.6204	8.214	0.00000000468 ***
Estriol	0.6082	0.1468	4.143	0.000271 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for gaussian family taken to be 14.60088)

Null deviance: 674.00 on 30 degrees of freedom
Residual deviance: 423.43 on 29 degrees of freedom
AIC: 175.02

		2.5 %	97.5 %
(Intercept)	21.5234286	16.3875056	26.6593515
Estriol	0.6081905	0.3204448	0.8959362

결론

- 회귀직선: 출생시 체중 = $21.5234 + 0.6082 \times \text{호르몬 수치}$
- $\hat{\beta}_1 = 0.6082$, $p\text{-value} < 0.05$
 - 산모의 Estriol 수치가 1mg/24hr 증가할 때 아기의 출생시 체중은 평균 60.82g 증가할 것으로 예측됨
 - 산모의 Estriol 수치는 아기의 출생시 체중에 유의한 효과를 가짐
- $\hat{\beta}_0 = 21.5234$

```
# 데이터 가져오기
data <- read.csv('C:/Users/sangahchi/Downloads/10/birthwe

# 설명변수 범주화
data$smoke <- factor(data$smoke, levels=c("No", "Yes"))

# 선형 모형 적합
model <- glm(bwt ~ smoke, data=data)

# Coefficient estimates
summary(model)
cbind(coef(model), confint(model))
```

No	Yes
115	74

```
call:
glm(formula = bwt ~ smoke, data = data)
```

```
Deviance Residuals:
    Min       1Q   Median       3Q      Max
-2062.9   -475.9    34.3    545.1   1934.3
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  3055.70      66.93   45.653 < 0.0000000000000002 ***
smokeYes     -283.78     106.97   -2.653    0.00867 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
(Dispersion parameter for gaussian family taken to be 515207)
```

```
Null deviance: 99969656 on 188 degrees of freedom
Residual deviance: 96343710 on 187 degrees of freedom
AIC: 3026.1
```

```
Number of Fisher Scoring iterations: 2
```

		2.5 %	97.5 %
(Intercept)	3055.6957	2924.5089	3186.8824
smokeYes	-283.7767	-493.4317	-74.1218

결론

- 회귀직선: 출생시 체중 = $3055.6957 + (-283.7767) * \text{산모의 흡연}$
- $\hat{\beta}_1 = -283.7767$, $p\text{-value} < 0.05$
 - 산모가 흡연을 할 경우, 흡연을 하지 않을 경우보다 아기의 출생시 체중은 평균 283.7767g 감소할 것으로 예측됨
 - 산모의 흡연 여부는 아기의 출생시 체중에 유의한 효과를 가짐
- $\hat{\beta}_0 = 3088.6957$

설명변수 범주화

```
data$race <- factor(data$race)
```

	1	2	3
	96	26	67

선형 모형 적합 및 Coefficient estimates

```
model <- glm(bwt ~ race, data=data)
```

```
summary(model)
```

```
cbind(coef(model), confint(model))
```

Type III p-value

```
library(aod)
```

```
wald.test(b = coef(model), Sigma = vcov(model), Terms = 2:3)
```

참고. Type III p-value

각 변수 자체의 효과에 대한 검정

call:

```
glm(formula = bwt ~ race, data = data)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2096.28	-502.72	-12.72	526.28	1887.28

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3102.72	72.92	42.548	< 0.0000000000000002 ***
race2	-383.03	157.96	-2.425	0.01627 *
race3	-297.44	113.74	-2.615	0.00965 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

		2.5 %	97.5 %
(Intercept)	3102.7187	2959.7923	3245.64516
race2	-383.0264	-692.6298	-73.42305
race3	-297.4352	-520.3654	-74.50498

wald test:

Chi-squared test:

X2 = 9.8, df = 2, P(> X2) = 0.0074

결론

- 회귀직선: 출생시 체중 = $3055.6957 + (-383.0264) * \text{Black} + (-297.4352) * \text{Other}$
- $\hat{\beta}_{black} = -383.0264$, $\hat{\beta}_{other} = -297.4352$, all p-value < 0.05
 - 흑인 산모의 경우, 백인 산모보다 아기의 출생시 체중은 평균 383.0264g 감소할 것으로 예측됨
 - 기타 인종 산모의 경우, 백인 산모보다 아기의 출생시 체중은 평균 297.4352g 감소할 것으로 예측됨
 - 산모의 인종은 아기의 출생시 체중에 유의한 효과를 가짐 (Type III p-value로 판단)
- $\hat{\beta}_0 = 3102.7187$

Regression Model

② Multiple Linear Regression

- 모형 $Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_k x_{ki} + \varepsilon_i, \quad \varepsilon_i \sim iid N(0, \sigma^2)$
- 기본 가정
 - 선형성 (Linearity)
 - 독립성 (Independence), 정규성 (Normality), 등분산성 (Equal variance), 오차의 평균은 0 (zero mean)
- 특정 설명변수와 결과변수 간의 연관성을 평가할 때, 다른 설명변수의 효과를 보정(adjust)하는 것이 필요함
- 교란인자나 보정변수들의 효과를 통제한 상태에서,
주요 관심있는 변수 (primary risk factor)의 순수한 효과를 보기 위함!

- 다변수 회귀분석에 포함할 설명변수들 선정이 필요함
 - 다변수 분석에 포함할 설명변수들 (주요 위험인자, 교란인자, 보정변수) 후보 리스트업

임상적인 고려
논문 리뷰나 임상 경험을 통해 '임상적 유의성/유용성' 이 알려진 변수들

&

통계적인 고려
단변수 분석 등 통계분석 결과를 통해 '통계적 유의성'이 알려진 변수들

- 설명변수들 간의 다중공선성 (높은 상관성) 검토 (**VIF < 5 or < 10**)
- 단변수 분석 (univariable p -value < 0.1)
- 변수선택법 적용 (variable selection)
- 정규화 (regularization) 회귀분석 사용
 - Ex. Ridge regression, LASSO 등

- 전진선택법 (forward selection)
 - 널 모형 (null model)에서 출발 $Y = \beta_0$
 - 설명변수 중에서 가장 크게 영향을 미칠 것 같은 변수부터 하나씩 포함하면서 변수선택 진행
 - 모형 적합도가 더 이상 개선되지 않으면 종료
- 후진제거법 (backward elimination)
 - 포화 모형 (full model)에서 출발 $Y = \beta_0 + \beta_1x_1 + \beta_1x_2 + \cdots + \beta_kx_k$
 - 설명변수 중에서 가장 적게 영향을 미칠 것 같은 변수부터 하나씩 제거하면서 변수선택 진행
 - 모형 적합도가 상당히 감소할 것 같으면 종료
- 단계별선택법 (stepwise selection)
 - 전진선택법과 후진제거법을 결합하여 진행

설명변수 범주화

```
data$smoke <- factor(data$smoke)
```

No	Yes
115	74

선형 모형 적합 및 Coefficient estimates

```
model <- glm(bwt ~ age + smoke, data=data)
```

```
summary(model)
```

```
cbind(coef(model), confint(model))
```

다중공선성 확인

```
library(car)
```

```
vif(model)
```

age	smoke
1.00197	1.00197

Call:

```
glm(formula = bwt ~ age + smoke, data = data)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2119.98	-442.66	52.92	532.38	1690.74

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2791.224	240.950	11.584	<0.0000000000000002 ***
age	11.290	9.881	1.143	0.255
smokeYes	-278.356	106.987	-2.602	0.010 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

		2.5 %	97.5 %
(Intercept)	2791.22431	2318.971775	3263.47685
age	11.28961	-8.077542	30.65676
smokeYes	-278.35613	-488.046399	-68.66586

결론

- 회귀직선: 출생시 체중 = $2791.2243 + 11.2896 * \text{산모 나이} + (-278.3561) * \text{흡연}$
- $\hat{\beta}_{\text{smoke}} = -278.3561$, $p\text{-value} < 0.05$
 - 산모 나이가 일정하다고 가정할 때 (산모 나이를 보정할 때)
산모가 흡연을 할 경우, 흡연을 하지 않을 경우보다 아기의 출생시 체중은 평균 278.3561g 감소할 것으로 예측됨
 - 산모 나이를 보정한 후에도, 산모의 흡연 여부는 아기의 출생시 체중에 유의한 효과를 가짐
- $\hat{\beta}_0 = 2791.2243$

R 실습

1. 실습자료인 birthweight 자료를 불러오고, 산모의 마지막 생리때의 체중 (lwt)과 아기의 출생시 체중 (bwt)의 분포를 확인하라.
2. 산모의 마지막 생리때의 체중 (lwt)과 아기의 출생시 체중 (bwt)간의 연관성을 확인하기 위해 산점도를 그려라. (단, ggplot 함수 사용)
3. 2번의 산점도에 선형 회귀직선을 그려라. (단, ggplot 함수의 geom_smooth 함수 사용)
4. 산모의 마지막 생리때의 체중 (lwt)과 아기의 출생시 체중 (bwt)간의 상관계수를 추정하고 유의성을 확인하라.

1. birthweight 자료에서 산모의 나이(age)로 아기의 출생시 체중(bwt)를 예측할 수 있는 회귀식을 추정하고 추정된 회귀계수를 해석하라.

2. 1번의 추정된 회귀식에 대한 유의성과 설명력을 확인하라.

3. 산모의 나이(age), 인종(race) 및 흡연여부(smoke)로 아기의 출생시 체중(bwt)를 예측할 수 있는 회귀식을 추정하고 추정된 회귀계수를 해석하라.

4. 3번의 추정된 회귀식의 다중공선성을 확인하고 해석하라.

If you have ANY question,
please contact to
sszzgg91@naver.com